Stromverbrauch Vorhersagen

20.5.2026

Machine Learning für den stündlichen
Stromverbrauch in Deutschland

Projektziel und ML-Ablauf

- Stündlicher Stromverbrauch in Deutschland anhand der historischen Daten und der Wettervorhersage vorhersagen

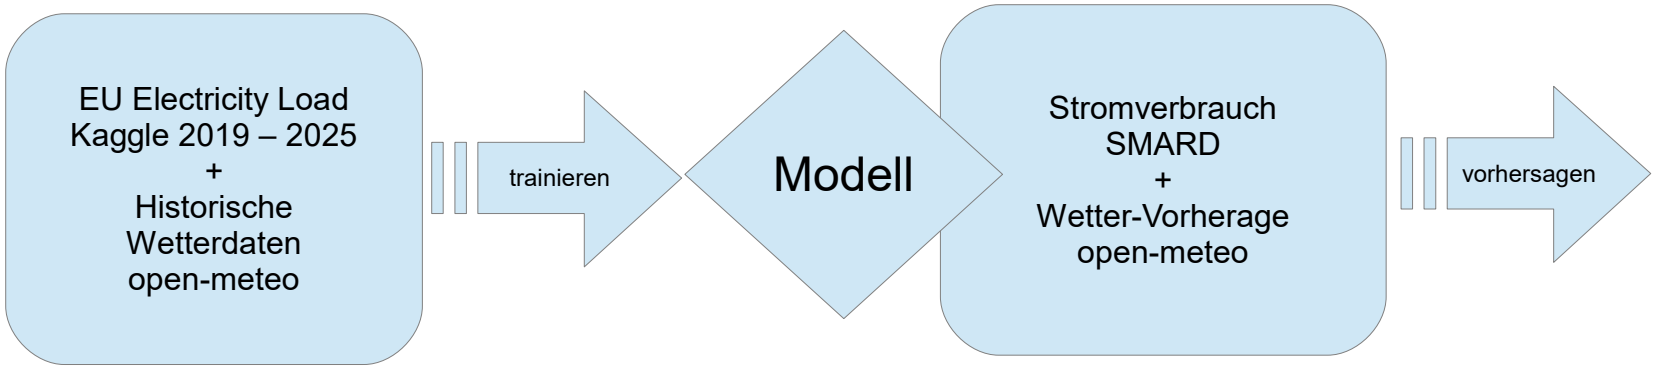

EDA - Datenselektion

- Landselektion – Deutschland (DE)
- Relevante Wettervariablen:
  - temperature_2m, apparent_temperature, rain, snowfall, wind_speed_10m, shortwave_radiation
- Die Population der 5 größten Städte als Gewicht für Kalkulation der Wettervariablen
  - Berlin, Hamburg, München, Köln, Frankfurt

EDA – Stromverbrauch Muster

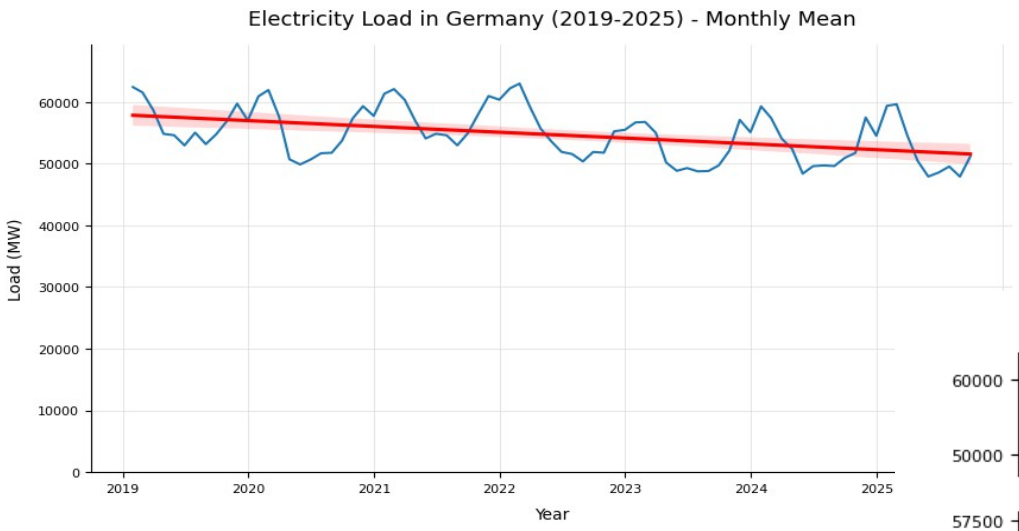

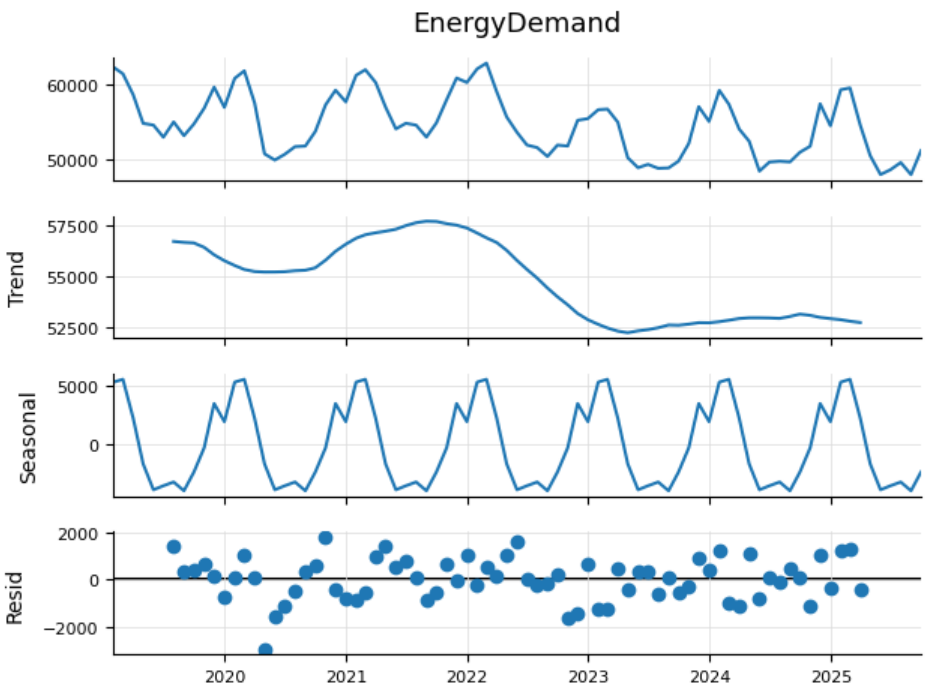

EDA – Wetter-Stromverbrauch

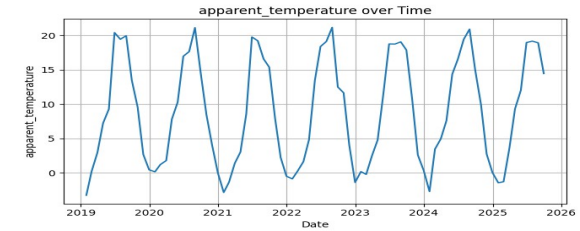

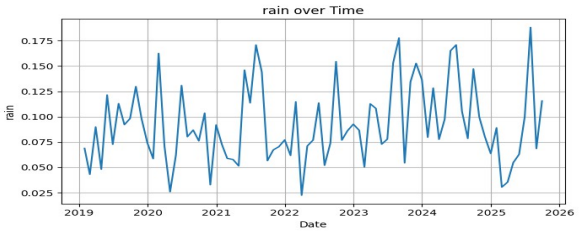

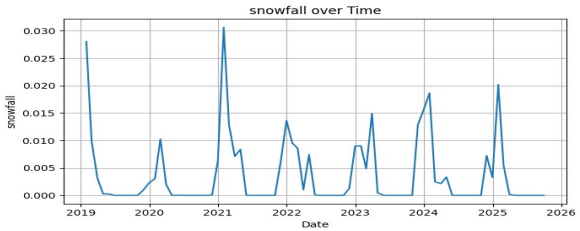

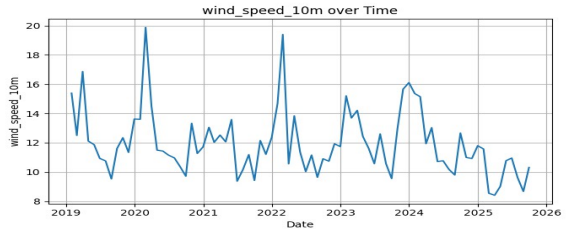

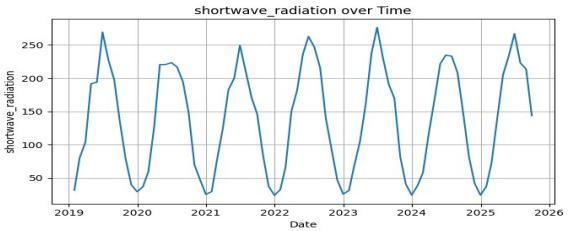

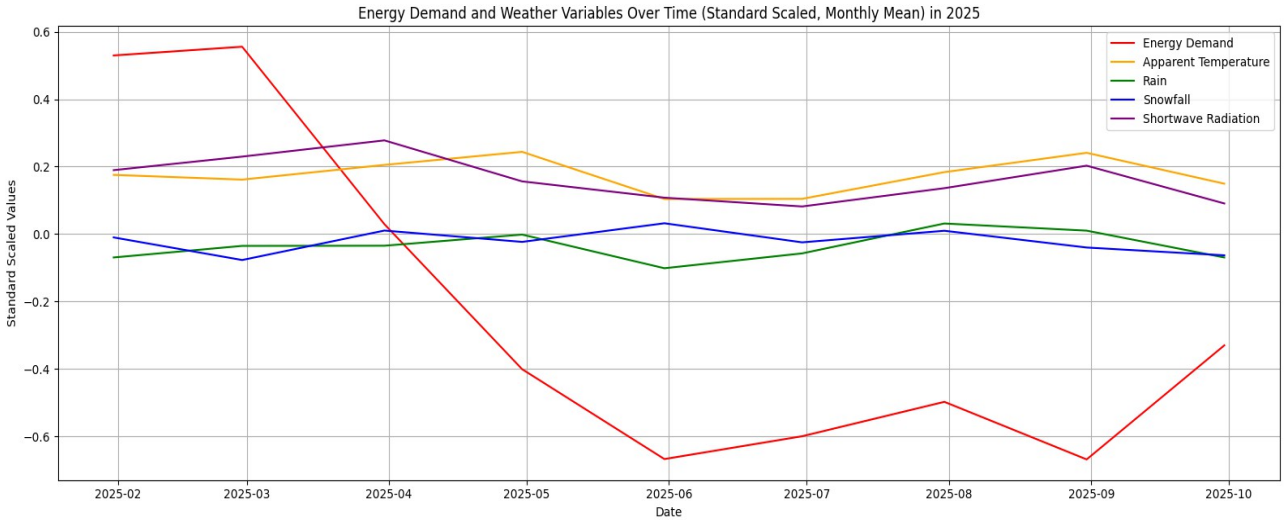

Marktdaten

- Stromverbrauchverteilung

* Quelle: de.statista.com

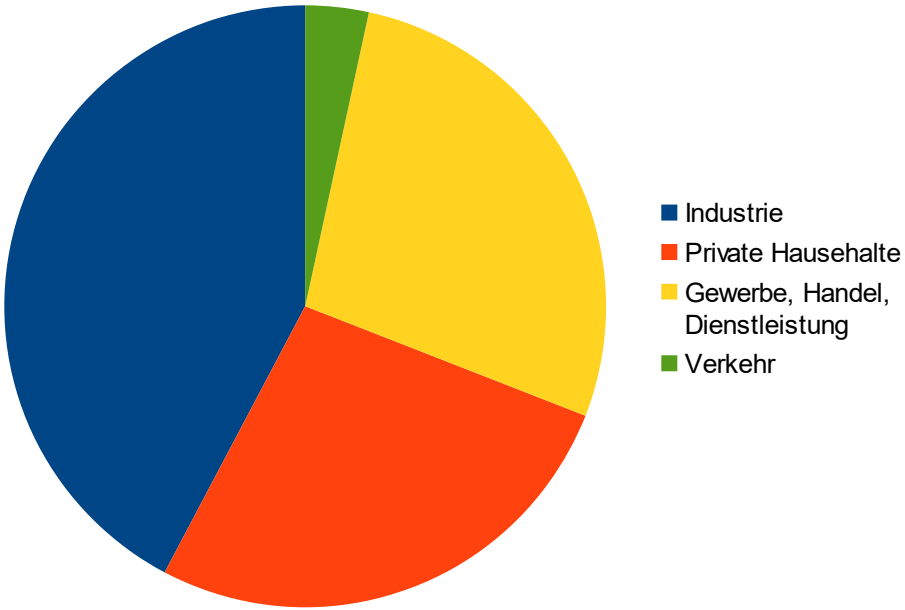

- Einflussfaktoren
  - Zeit
    - Saisonzyklen
    - Feiertage
  - Wetter
    - Temperatur
    - Sonnenstralung
    - Wind
    - Regen oder Schnee
  - Konjunktur
    - Nur Langzeitwirkung

Feature Engineering

- Zeit basierte Features
  - Year, month, weekday, is_weekend, is_holiday, holiday_ratio(Länderanteil), holiday_weight(Brückentag), is_pandemic_time
- Wetter basierte Features
  - heating_degree, cooling_degree
- Zeitreihen – lag und rolling, Tag und Woche
  - EnergyDemand
  - apparent_temperature, shortwave_radiation
  - Ursprünglich auch 8760h (Jahr)

Basis-Modelle und Bewertungen

Basis-Modell (default parameters)	MAE	MSE	R^2
Linear Regression	2547	10482714	0.87
Random Forest Regressor	1575	4526659	0.94
SVR	7396	79318339	0.01
XGBoost	1763	5523347	0.93
LightGBM	1671	4743086	0.94
SARIMAX*	468	351086	0.99

* Wegen großes Rechenaufwandes auf täglichen Datensatz reduziert

mit RandomSearch Tuned Modell	MAE	MSE	R^2
Random Forest Regressor	2026	7926521	0.90
LightGBM	1728	5029289	0.94

Basis-Modelle und Bewertungen

Basis-Modell (default parameters)	MAE	MSE	R^2
Linear Regression	2547	10482714	0.87
Random Forest Regressor	1575	4526659	0.94
SVR	7396	79318339	0.01
XGBoost	1763	5523347	0.93
LightGBM	1671	4743086	0.94
SARIMAX*	468	351086	0.99

* Wegen großes Rechenaufwandes auf täglichen Datensatz reduziert

mit RandomSearch Tuned Modell	MAE	MSE	R^2
Random Forest Regressor	2026	7926521	0.90
LightGBM	1728	5029289	0.94

Modelle Tuning - Bayesian Optimazition

	MAE	RMSE	R^2	Train duration
LightGBM	1278.89	1657.22	0.9656	2'30"
Random Forest	1319.47	1754.03	0.9615	22'30

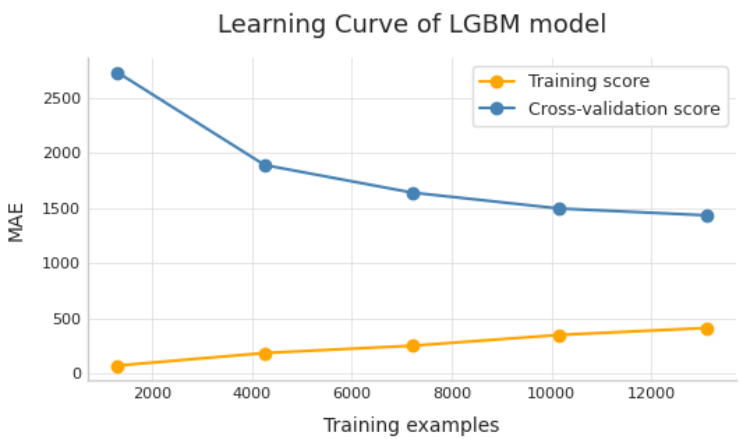

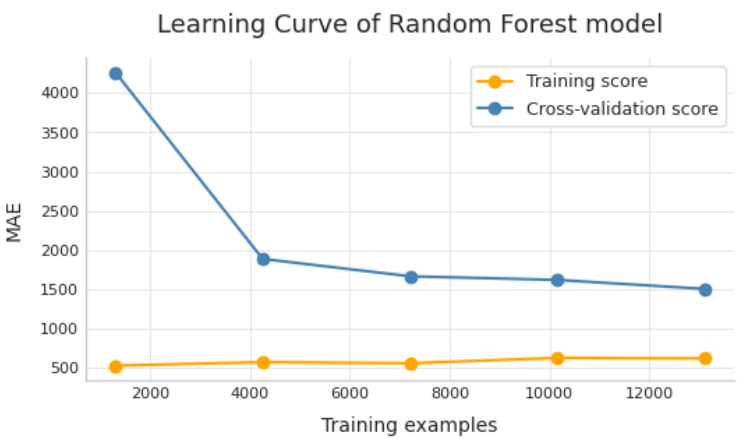

Feature Importances

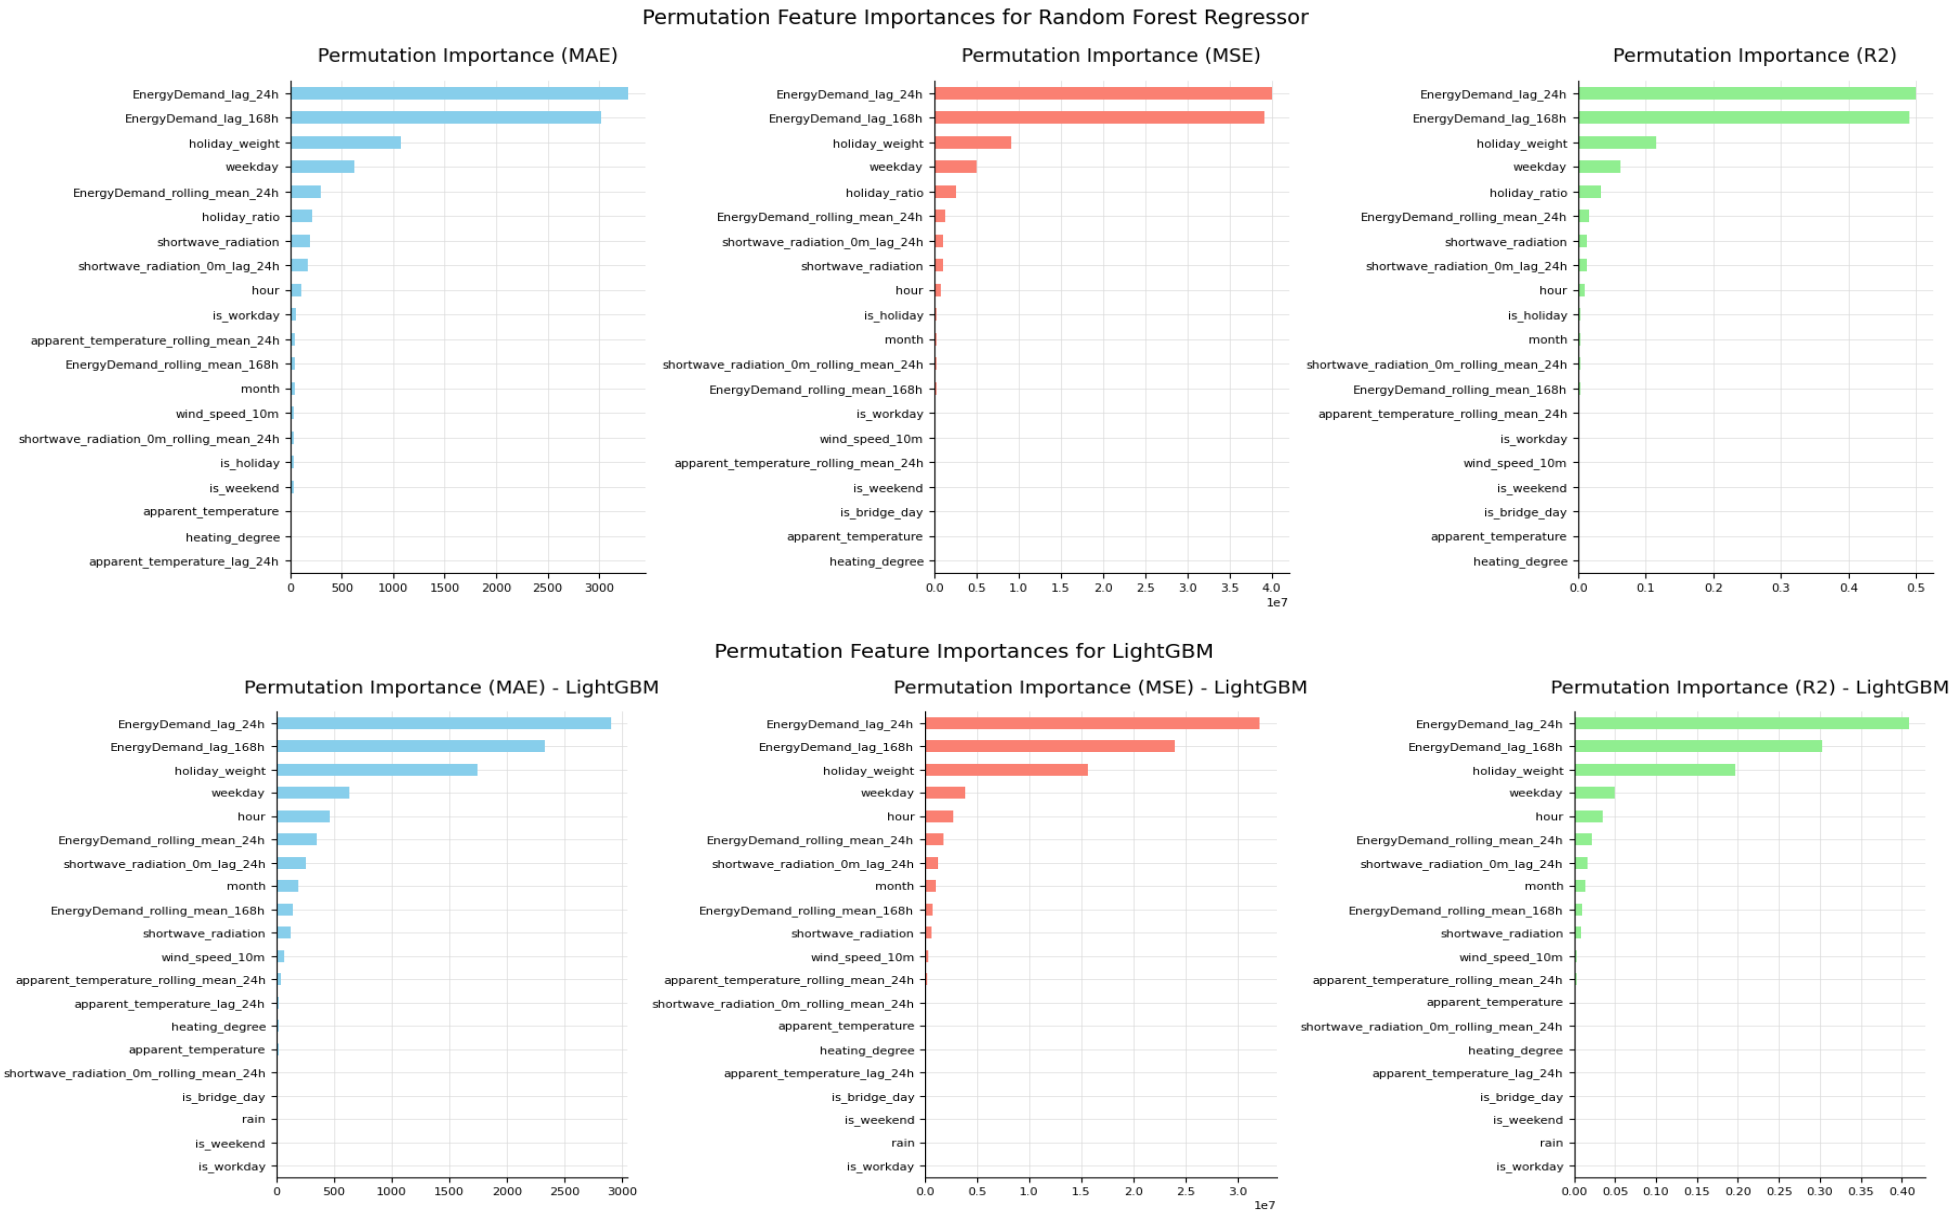

Vorhersage GUI - morgen

Deploy

Vorhersagetag: 2026-05-16

LGBM

Predict for Tomorrow

Vorhersage abgeschlossen — 2026-05-16 (LGBM)

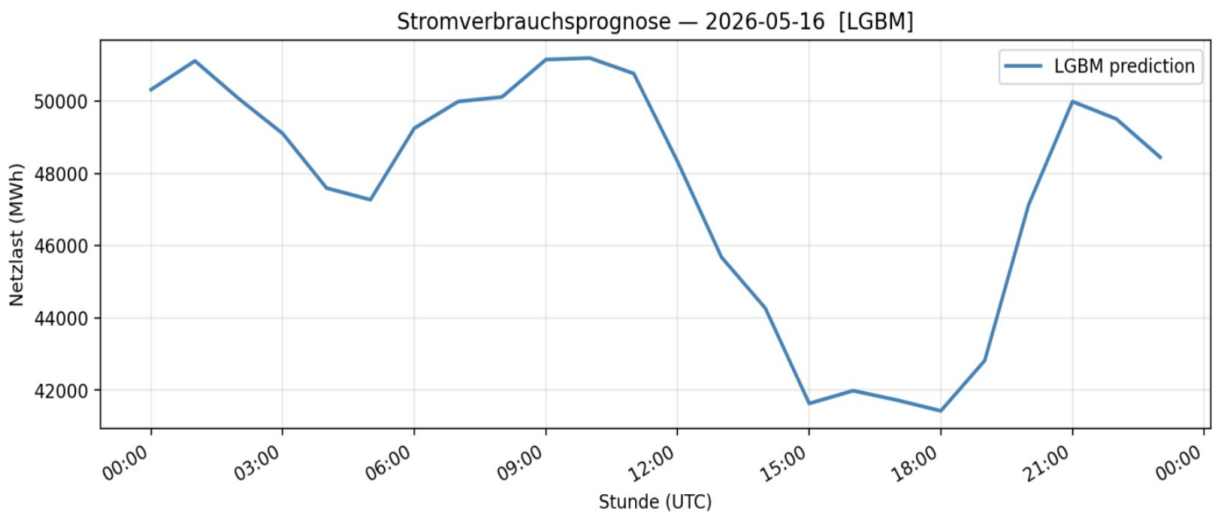

	Stunde (UTC)	predicted_MWh
0	00:00	50317
1	01:00	51111
2	02:00	50065
3	03:00	49101
4	04:00	47593
5	05:00	47270
6	06:00	49248
7	07:00	49987
8	08:00	50114
9	09:00	51149
10	10:00	51191
11	11:00	50762
12	12:00	48325
13	13:00	45681
14	14:00	44268
15	15:00	41631

Vorhersage vs realer Verbrauch

Deploy

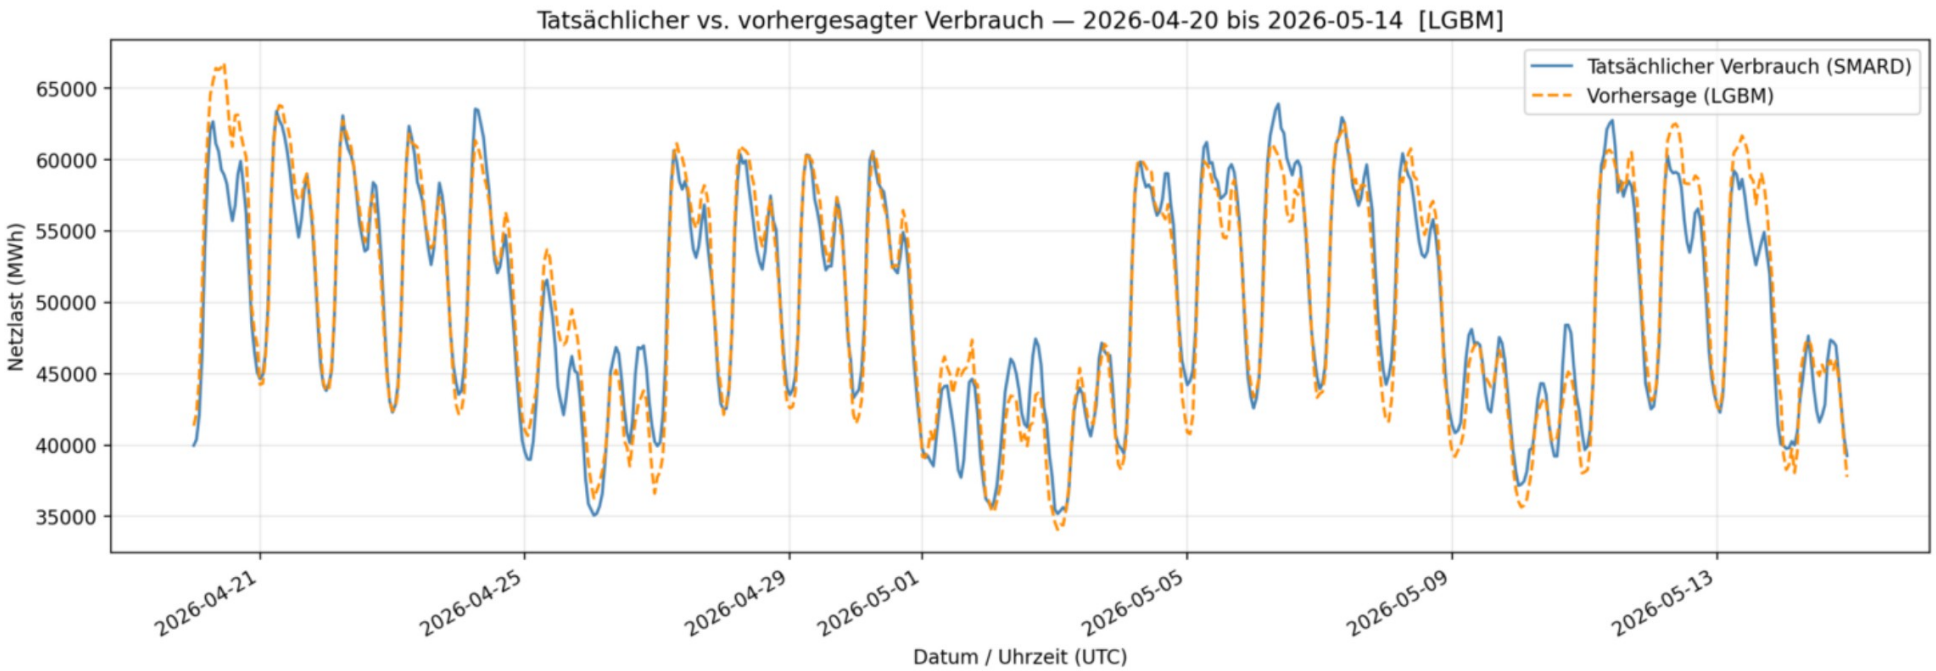

MAE
1,575 MWh

RMSE
2,025 MWh

Datenpunkte
600

Fazit

- Befund
  - Der kurzfristige künftige Stromverbrauch hängt stark von den vorangegangenen/historischen Werten ab
  - Zeitlichen Faktor - arbeitsfreie Tage (Feiertage, Wochenende und Brückentage) spielen auch eine wichtige Rolle. Dies bestätigt die Verteilung des Marktes
  - Wetter beeinflusst den gesamten Verbrauch nur geringfügig
- Langzeit-Vorhersage benötigt anderen Daten und Modelle